Analiza i Wizualizacja Danych

Data Analysis and Visualization

Przedmiot prowadzony jest dla studentów 2-ego roku kierunku kognitywistyka na Uniwersytecie Adama Mickiewicza w Poznaniu.

Kontakt do prowadzącego

mgr Agnieszka Smolnicka, agnieszka.smolnicka@amu.edu.pl, dyżur: wtorek 15:15-16:15, pokój 110 (bud. AB)

Organizacja zajęć

1. 13 zajęć laboratoryjnych
2. ukończenie projektu realizowanego w trakcie

Terminarz zajęć

Nr	Temat	Biblioteka	Data gr. 1,2 (pon)	Data gr. 3,4 (wt)	Zadanie domowe	Pkt	Termin
1.	Obliczenia numeryczne 1	`notebook`, `numpy`	5.10	6.10			
2.	Obliczenia numeryczne 2	`numpy`	12.10	13.10			
	Przetwarzanie danych 1	`pandas`			1. zbiór danych	4.5	
3.	Wizualizacja danych numerycznych	`matplotlib`	19.10	20.10			zad. 1
4.	Przetwarzanie danych 2	`pandas`	26.10	27.10	2. problemy badawcze	2	
5.	Przetwarzanie danych 3/4	`pandas`	9.11	10.11 *			zad. 2
6.	Czyszczenie danych 1	`pandas`, `pyjanitor`	16.11	17.11			
7.	Czyszczenie danych 2	`pandas`, `pyjanitor`	23.11	24.11	3. oczyszczenie danych	4.5	

Nr	Temat	Biblioteka	Data gr. 1,2 (pon)	Data gr. 3,4 (wt)	Zadanie domowe	Pkt	Termin
8.	Agregacje	`pandas`	30.11	1.12	Lista zadań - przetwarzanie danych	16	zad. 3
9.	Wizualizacja zmiennych 1	`seaborn`	7.12	8.12			
10.	Wizualizacja zmiennych 2	`seaborn`	14.12	15.12	4. agregacje i wykresy	12.5	lista zadań
11.	Testowanie statystyczne 1	`pingouin`	21.12	22.12			zad. 4
12.	Testowanie statystyczne 2	`pingouin`	11.01	12.01			
13.	Raportowanie		18.01	19.01	5. testy statystyczne	9.5	
					6. raport statystyczny	14	
			1.02	2.02			zad. 5 i 6
					Razem	63	

* brak zajęć 3.11 ze względu na poprzedzający go dzień rektorski 2.11 \

💯 Kryteria oceny z przedmiotu

Łącznie na przedmiocie można zdobyć maksymalnie 63 punkty, na co składa się:

- 47 punktów za projekt,
- 16 punktów za listę zadań z części dotyczącej przetwarzania danych.

Kolejnym ocenom z przedmiotu odpowiadają następujące przedziały punktów:

Ocena	Liczba punktów
bardzo dobry (5,0)	[57; 63]
dobry plus (4,5)	[51; 57)
dobry (4,0)	[45; 51)
dostateczny plus (3,5)	[40; 45)
dostateczny (3,0)	[35; 40)

Ocena	Liczba punktów
niedostateczny (2,0)	[0; 35)

Warunkiem zaliczenia poza osiągnięciem odpowiednio wysokiej łącznej sumy punktów, zgodnej z powyższą tabelą, jest uzyskanie minimum połowy punktów za zadanie 6 - końcowy etap projektu (7 z 14 punktów).

Dozwolone są maksymalnie 2 nieobecności, przy czym odbycie konsultacji projektowej jest obowiązkowe.

W przypadku nieosiągnięcia łącznej liczby punktów wystarczającej do zdania, możliwa jest jednorazowa poprawa całości projektu, a w przypadku niespełnienia warunku dotyczącego zadania 6 - poprawa niego samego. W razie poprawy całości projektu, po obowiązkowym indywidualnym umówieniu się odbyłaby się konsultacja poprojektowa na jego temat.

Projekt

Celem projektu jest zbadanie zależności między 5 parami zmiennych wybranego przez siebie zestawu danych oraz zaprezentowanie otrzymanych wyników w postaci raportu. Projekt będzie realizowany w etapach wyznaczonych przez kolejne tematy omawiane na zajęciach, zgodnie z harmonogramem wyżej. Dokładna treść poszczególnych zadań i miejsce na wstawienie swoich rozwiązań znajduje się na platformie Moodle. Każdy etap poza ostatnim należy wykonać do czasu następnych zajęć, natomiast finalna wersja projektu powinna zostać umieszczona na stronie na 4 dni przed swoją konsultacją poprojektową.

Lista zadań

Lista zadań ma na celu uzupełnienie projektu pod względem głębszego sprawdzenia umiejętności przetwarzania danych. Zawiera ona 14 krótkich podpunktów do rozwiązania na swoim projektowym zbiorze danych (Moodle). W skład jej oceny wchodzą odpowiedzi do zadań oraz ich odpowiedni komentarz. Na czas wykonania listy zadań jest dwa tygodnie od jej zadania, czyli od zajęć nr 6.

Zasady używania GenAI

W projekcie

Podczas wykonywania projektu dozwolone jest korzystanie z GenAI jako:

- interaktywnej formy dokumentacji bibliotek Pythona,
- lokalizatora błędów w kodzie
- wsparcia w znalezieniu rozwiązania problemu analitycznego o niskiej złożoności i niestanowiącego kluczowej części zadania.

Niezależnie od formy użycia konieczne jest jednak szczegółowe zrozumienie otrzymanych wyników oraz umiejętność i gotowość udzielenia odpowiedzi na związane z nimi pytania. Skorzystanie z GenAI w formie trzeciej z wymienionych wymaga ponadto wskazania w plikach załączonych do danego zadania miejsca i zakresu jej użycia.

Zabronione jest korzystanie z GenAI do rozwiązywania problemów stanowiących znaczące części zadań i problemów, w których wyręczenie przez GenAI spowodowałoby nieosiągnięcie zakładanych efektów

uczenia się.

Podstawową zasadą, którą należy się kierować jest to, aby użycie GenAI było wspierające, a nie zastępujące - fragmenty definicji z regulaminu przedmiotu Reasoning:

- korzystanie wspomagające: „korzystanie w celu ułatwienia, wyjaśnienia lub udoskonalenia samodzielnej pracy studenta; student pozostaje głównym autorem, projektantem i decydentem; AI pełni rolę korepetytora lub wyspecjalizowanego redaktora, a nie twórcy''
- korzystanie zastępujące: „korzystanie, w którym AI wykonuje istotne czynności poznawcze przewidziane przez efekty kształcenia danego zadania; w tym trybie AI staje się głównym wnioskującym, autorem lub rozwiązującym problem,
  a student zostaje sprowadzony do roli twórcy promptów lub redaktora technicznego. Tego rodzaju użycie omija proces uczenia się.''

W liście zadań

Podczas rozwiązywania listy zadań z przetwarzania danych korzystanie z GenAI jest zabronione. Wynika to z małej złożoności zadań oraz ich celu, którym jest samodzielne dopasowanie odpowiedniej metody do problemu i wywnioskowanie szczegółów jej zastosowania, korzystając jedynie z udostępnionych materiałów oraz dokumentacji Pythona.

DataCamp

Darmowy dostęp do popularnej platformy z kursami z analizy danych i programowania:

grupa DataCamp

Dostęp za pomocą maila uczelnianego trwa do 22 marca (lub dłużej po zgłoszeniu się do mnie).

Przydatne kursy można znaleźć w zakładce Learn (na górze) $\rightarrow$ Courses (oraz Learn $\rightarrow$ Assignments)).

Kursy

1. Obliczenia numeryczne
   - Introduction to NumPy
2. Wizualizacja danych numerycznych
   - Introduction to Data Visualization with Matplotlib → Introduction to Matplotlib, Sharing visualizations with others
3. Przetwarzanie danych
   - Intermediate Python → Dictionaries & Pandas
   - Introduction to Importing Data in Python → Introduction and flat files
   - Data Manipulation with pandas
     Rozszerzenie:
   - Reshaping Data with pandas
   - Joining Data with pandas
4. Czyszczenie danych
   - Cleaning Data in Python
5. Agregacje

    - Introduction to Statistics in Python → Summary Statistics
6. Wizualizacja zmiennych
    - Introduction to Data Visualization with Seaborn
      Alternatywa:
    - Introduction to Data Visualization with Matplotlib → Quantitative comparisons and statistical visualizations
      Rozszerzenie:
    - Improving Your Data Visualizations in Python
7. Testowanie statystyczne
    - Hypothesis Testing in Python
    - Exploratory Data Analysis in Python
      Rozszerzenie:
    - Introduction to Statistics in Python → Correlation and Experimental Design
    - Experimental Design in Python
    - Foundations of Inference in Python

Ścieżki

Ścieżki składają się z kilku powiązanych kursów - wyżej wymienionych oraz zbliżonych do nich tematycznie.

- Python Data Fundamentals (podstawy Pythona; podstawy `matplotlib` i `numpy`; `pandas`; `seaborn`)
- Data Manipulation in Python (`numpy`; `pandas`)
- Importing & Cleaning Data in Python (`pandas`)
- Data Visualization in Python (`matplotlib`; `seaborn`)

💻 Instalacja Jupyter Notebook

W wierszu poleceń:

```
pip install notebook
```

Aby uruchomić notebook wpisujemy w wierszu poleceń:

```
jupyter notebook
```

lub (bardziej skuteczne, jeśli nie mamy polecenia `jupyter`)

```
python -m notebook
```

Środowisko Dziobak - chmura na pliki: http://150.254.90.119:13120
Logowanie za pomocą loginu z USOSa i hasła ustalonego przy pierwszym logowaniu (do Dziobaka).